

Resolução do Item (b): Modelagem Analítica (Fila $M/M/1$)

Sob o roteamento aleatório, o teorema do *splitting* garante que cada um dos três servidores recebe um processo de Poisson independente com taxa $\lambda_i = \lambda/3$ [cite: 1, 2]. Com a taxa de serviço exponencial μ , a intensidade de tráfego de cada servidor individual é $\rho_i = \lambda/(3\mu)$ [cite: 1]. A partir da distribuição estacionária da fila $M/M/1$ dada por $p_k = (1 - \rho_i)\rho_i^k$ [cite: 2], deduzem-se as seguintes métricas:

- **Utilização (U_i):** Representa a probabilidade de o servidor estar ocupado (não estar vazio). Sabendo que a probabilidade de haver k requisições no servidor é $p_k = (1 - \rho_i)\rho_i^k$ [cite: 2], a probabilidade de o servidor estar ocioso ($k = 0$) é calculada como:

$$p_0 = (1 - \rho_i)\rho_i^0 = 1 - \rho_i$$

Logo, a utilização é dada pela probabilidade complementar (o sistema não estar no estado zero):

$$U_i = 1 - p_0 = 1 - (1 - \rho_i) = \rho_i[\text{cite: 1}].$$

- **Número médio de requisições no servidor ($E[N_i]$):** A esperança matemática da distribuição resulta em $E[N_i] = \rho_i/(1 - \rho_i)$ [cite: 1].
- **Tempo médio de resposta ($E[R]$):** Pode ser deduzido aplicando a Lei de Little para um único servidor, que estabelece a relação $E[N_i] = \lambda_i E[R]$. Isolando $E[R]$ e substituindo a fórmula de $E[N_i]$ [cite: 1]:

$$E[R] = \frac{E[N_i]}{\lambda_i} = \frac{\frac{\rho_i}{1-\rho_i}}{\lambda_i}$$

Lembrando que a intensidade de tráfego genérica é $\rho_i = \lambda_i/\mu$, podemos substituir no numerador para simplificar a expressão:

$$E[R] = \frac{\frac{\lambda_i/\mu}{1-\rho_i}}{\lambda_i} = \frac{1}{\mu(1 - \rho_i)}$$

Por fim, substituindo a intensidade de tráfego específica desta política, que é $\rho_i = \lambda/(3\mu)$ [cite: 1], obtemos a equação final:

$$E[R] = \frac{1}{\mu \left(1 - \frac{\lambda}{3\mu}\right)} = \frac{1}{\mu - \frac{\lambda}{3}}[\text{cite: 1, 2}].$$

- **Tempo médio de espera na fila ($E[T_Q]$):** Subtraindo o tempo de serviço do tempo de resposta, tem-se $E[T_Q] = E[R] - 1/\mu = \rho_i/(\mu(1 - \rho_i))$ [cite: 1].
- **Vazão (X):** Em regime estacionário, $X = \lambda$ [cite: 1].
- **Estabilidade:** O sistema permanece estável (sem filas infinitas) desde que a taxa de chegada seja inferior à capacidade total de serviço, ou seja, $\lambda < 3\mu$ [cite: 1].

Abaixo está a tabela com os valores analíticos calculados para cada taxa λ do experimento (considerando $\mu = 1, 0$):

λ (req/u.t.)	ρ_i (Utilização U_i)	$E[N_i]$	Vazão (X)	$E[R]$ (u.t.)
0.6	0.20	0.25	0.6	1.25
1.2	0.40	0.67	1.2	1.67
1.8	0.60	1.50	1.8	2.50
2.4	0.80	4.00	2.4	5.00
2.7	0.90	9.00	2.7	10.00

Nota: Tabela adaptada dos dados analíticos apresentados no relatório[cite: 1].

Resolução do Item (c): Conservação de Trabalho

A vazão efetiva X e a utilização individual U_i deduzidas no modelo aleatório são válidas para todas as três políticas implementadas[cite: 1]. Isso se baseia no princípio de conservação de trabalho: assumindo que o sistema é estável e a fila é ilimitada, toda requisição que entra no sistema será invariavelmente atendida por um dos servidores[cite: 2]. O relatório confirma essa propriedade empírica, registrando que a simulação obteve uma vazão X igual a λ e uma utilização média $U_i = \lambda/3$ consistentemente ao longo de todas as políticas de balanceamento testadas[cite: 1].

Resolução do Item (d): Comparação das Políticas ($E[R]$)

Os dados da simulação atestam estritamente a ordenação esperada: $E[R]_{JSQ} \leq E[R]_{RR} \leq E[R]_{Random}$ [cite: 1].

- O modelo $E[R] \approx 1/(\mu - \lambda/3)$ descreve apenas a política Aleatória, que resulta nos maiores tempos de resposta[cite: 1, 2].
- Essa ordenação ocorre porque o roteamento aleatório pode enviar requisições repetidamente para um mesmo servidor por mero acaso, gerando acúmulo temporário em uma fila enquanto outras ficam ociosas. O Round-Robin (RR) mitiga esse problema ao impor uma distribuição perfeitamente equitativa a cada ciclo, enquanto a política da Fila Mais Curta (JSQ - *Join the Shortest Queue*) é a mais eficiente pois monitora ativamente o estado do sistema, minimizando buracos de ociosidade e mantendo as cargas estritamente niveladas.
- Em termos de ganho, a implementação de políticas informadas sobre o estado do sistema (JSQ e RR) proporciona uma redução expressiva no tempo médio de resposta, chegando a diminuir o $E[R]$ em até 59% sob alta carga ($\lambda = 2.7$) quando comparadas à escolha aleatória cega[cite: 1].